Muon 优化器：从损失到矩阵更新

概念、严谨证明与受控数值实验（第二版）

算法与数值实验报告

摘要

理解 Muon 的关键，是沿着“损失定义目标、梯度给出局部变化、方向决定往哪里走、内积衡量一阶收益、范数约束步幅、动量整合历史、SVD/NS 改变矩阵谱”的链条阅读算法。本文从这条链条出发，完整保留并细化精确版本、带动量版本及有限步近似版本的证明。在确定性全梯度、光滑、有下界、无衰减和无形状缩放的条件下，精确版本的时间平均梯度核范数可取得 $O(T^{-1/2})$ 上界；五步 NS 只能直接应用含近似误差的界。原有 140 组独立预算实验全部满足上界。本版新增 80 组同初值、同学习率、同预算的因子对照，分别观察动量、近似方法与步长日程；明确区分独立预算 T 与当前步数 t，以及平均梯度、当前梯度与损失。全部结果用于解释明示设定下的数学与数值行为。

1 引言：为什么需要这一串概念

优化训练首先需要一个标量目标 f，但标量本身没有告诉我们应如何改动数百个矩阵元素。梯度把目标变成参数空间中的局部变化信息；优化器再把梯度变成更新。由此自然产生三个问题：更新是否朝下降方向，更新一次会走多远，有限次更新后究竟能保证什么。内积、范数和光滑性分别回答这些问题。Muon 进一步利用矩阵的奇异方向，因而需要 SVD 来解释其几何含义，并用 Newton–Schulz（NS）多项式给出可执行的近似路径。

Jordan 等人的实现[1, 3]使用动量和少量五阶 NS 迭代，主要更新隐藏层矩阵；嵌入、输出层和偏置等交给 AdamW。Liu 等人[2]研究了权重衰减和尺度约定，并用于 Moonlight 训练。这些应用说明研究价值，本文的收敛命题则是针对下文假设的自包含推导。本文分别回答概念的用途、证明的条件和实验能支持的结论。

2 从目标到一次更新：概念与意义

2.1 损失：定义想改善什么

设矩阵参数 $W \in \mathbb{R}^{m\times n}$，训练目标为 $f(W)$。监督学习常写成

$$f(W) = \frac{1}{N}\sum_{i=1}^{N} \ell(h_W(x_i), y_i),$$

其中 h_W 是预测器，ℓ 衡量单个预测与目标的差异。平均损失把样本上的表现合并成一个需要减小的数。训练损失使用训练数据，测试损失使用未参与更新的数据；二者回答拟合与泛化的不同问题。本文矩阵实验直接构造 f，不需要预测器或数据集。

“损失小”不能替代“接近驻点”。给目标加常数 c，$f+c$ 的梯度和全部更新不变，损失数值却改变。反过来，梯度为零也可能是非凸函数的局部极大点，例如 $f(x)=1+\cos x$ 在 $x=0$ 处满足 $f'(0)=0$。因此后文分别报告损失和梯度，不能把驻点保证写成全局最优保证。

2.2 梯度与更新方向：局部信息如何变成行动

矩阵梯度 $G=\nabla f(W)$ 的第 (i,j) 项是对 W_{ij} 的偏导数。对于微小扰动 Z，

$$f(W+Z)=f(W)+\langle G,Z\rangle+o(\|Z\|_{\mathrm{F}}). \tag{1}$$

这说明梯度的意义是预测局部变化，而不是直接度量当前损失大小。

本文统一写成 $W_{t+1}=W_t-\eta_t D_t$，其中 $\eta_t>0$ 是学习率，D_t 是*被减去的方向矩阵*，实际位移是 $-\eta_t D_t$。代入式(1)，一阶变化为 $-\eta_t\langle G_t,D_t\rangle$。所以 $\langle G_t,D_t\rangle>0$ 时，$-D_t$ 才是局部下降方向；若步长过大，曲率效应仍可能使实际损失上升。

普通梯度下降取 $D_t=G_t$，因而一阶收益为 $\eta_t\|G_t\|_{\mathrm{F}}^2$。Muon 先处理动量，再重塑矩阵奇异值，通常 $D_t\neq G_t$。把“梯度”和“更新方向”分开，才能说明这种重塑到底保留了什么、改变了什么。

2.3 内积与范数：收益、幅度和约束如何配合

矩阵内积是

$$\langle A,B\rangle=\mathrm{tr}(A^{\top}B)=\sum_{ij}A_{ij}B_{ij}.$$

它把两个同形矩阵的对应元素相乘后相加。非零矩阵还可定义 $\cos\theta=\langle A,B\rangle/(\|A\|_{\mathrm{F}}\|B\|_{\mathrm{F}})$。内积既含方向对齐程度，也含幅度；不能只凭内积大小说夹角更小。设矩阵奇异值为 $\sigma_1,\dots,\sigma_r$，$r=\min(m,n)$，则

$$\|A\|_{\mathrm{F}}=\sqrt{\sum_{ij}A_{ij}^2}=\sqrt{\sum_i\sigma_i^2}, \tag{2}$$

$$\|A\|_{\mathrm{op}}=\max_i\sigma_i=\max_{\|v\|_2=1}\|Av\|_2, \tag{3}$$

$$\|A\|_*=\sum_i\sigma_i. \tag{4}$$

三者用途不同：Frobenius 范数量化整个参数位移及光滑误差；谱范数约束最强线性作用；核范数将作为谱范数约束下一阶收益的最优值。Cauchy–Schwarz 给出

$$|\langle A,B\rangle|\le\|A\|_{\mathrm{F}}\|B\|_{\mathrm{F}},\qquad \|A\|_{\mathrm{F}}\le\|A\|_*\le\sqrt{r}\|A\|_{\mathrm{F}}. \tag{5}$$

后一个上界是对奇异值向量使用 Cauchy–Schwarz；下界来自非负奇异值的平方展开。

“最速方向”必须附带约束。若 $G\neq0$，在 $\|D\|_{\mathrm{F}}\le1$ 下最大化 $\langle G,D\rangle$ 的方向为 $G/\|G\|_{\mathrm{F}}$；若没有幅度约束，内积可任意放大，不存在有限最优值。Muon 的精确几何解释采用的是谱范数约束。

2.4 SVD 与极分解：为什么重塑奇异值

设 $k = \mathrm{rank}(G)$，取只保留正奇异值的紧致 SVD：

$$G = U_k \Sigma_k V_k^\top = \sum_{i=1}^{k} \sigma_i u_i v_i^\top.$$

这里 v_i 给出输入空间方向，u_i 给出输出空间方向，σ_i 给出该成对方向的强度。定义精确极分解因子

$$\mathcal{P}(G) = U_k V_k^\top = \sum_{i=1}^{k} u_i v_i^\top, \qquad \mathcal{P}(0) = 0. \tag{6}$$

它保留这些方向，把每个正奇异值换成 1，从而削弱原先强方向相对弱方向的幅度优势。若 $G = \mathrm{diag}(10, 1)$，则普通梯度方向为 $\mathrm{diag}(10, 1)$，而精确方向为 I_2；两者不是简单地除以同一个数。

引理 1. 任意 G 的精确方向满足

$$\langle G, \mathcal{P}(G) \rangle = \|G\|_*, \qquad \|\mathcal{P}(G)\|_{\mathrm{op}} \le 1, \qquad \|\mathcal{P}(G)\|_{\mathrm{F}}^2 = k \le r. \tag{7}$$

并且

$$\max_{\|D\|_{\mathrm{op}} \le 1} \langle G, D \rangle = \|G\|_*. \tag{8}$$

证明. $u_i v_i^\top$ 在 Frobenius 内积下两两正交且范数为 1，故第一式为 $\sum_i \sigma_i$，方向的非零奇异值均为 1，得到另外两式。对任意可行 D，

$$\langle G, D \rangle = \sum_i \sigma_i u_i^\top D v_i \le \sum_i \sigma_i |u_i^\top D v_i| \le \sum_i \sigma_i \|D\|_{\mathrm{op}} \le \sum_i \sigma_i.$$

取 $D = \mathcal{P}(G)$ 达到等号。零矩阵时最优值与选定方向均为零。 □

这就是核范数进入收敛界的原因：它等于一步更新可获得的一阶收益，而位移代价由 $\|\mathcal{P}(G)\|_{\mathrm{F}}^2 \le r$ 控制。这里的“最速”指谱范数球内的线性化子问题，尚未计入有限步长的曲率项。

对于秩亏或矩形矩阵，$\mathcal{P}(G)$ 是部分等距映射，不能笼统说它的行列全都正交；例如 $G = \mathrm{diag}(10, 0)$ 时，选定方向是 $\mathrm{diag}(1, 0)$。代码用 float64 数值秩阈值处理近零奇异值，理论则保留全部严格正奇异值。因此浮点恒等式是在容限内核查的。精确方向对正数缩放满足 $\mathcal{P}(cG) = \mathcal{P}(G)$，这也说明在一维中它退化成符号方向，接近驻点时仍可能走固定长度。

2.5 动量：为什么使用历史，又会付出什么代价

设 $G_t = \nabla f(W_t)$，$M_{-1} = 0$，本文实现为

$$M_t = \beta M_{t-1} + (1 - \beta) G_t, \qquad 0 \le \beta < 1, \tag{9}$$

$$H_t = G_t + q(M_t - G_t), \qquad q = \begin{cases} 1, & \text{普通动量}, \\ \beta, & \text{Nesterov 风格混合}, \end{cases} \tag{10}$$

$$D_t = \mathcal{P}(H_t) \quad \text{或} \quad \mathrm{NS}_K(H_t), \tag{11}$$

$$W_{t+1} = (1 - \eta_t \lambda) W_t - \eta_t s D_t. \tag{12}$$

展开后 $M_t = (1-\beta)\sum_{j=0}^{t}\beta^{t-j}G_j$。它让邻近步骤的方向相互影响；当梯度有来回波动或随机噪声时，历史平均可能改善稳定性。它也会滞后于当前梯度，因而需要用 $\|H_t - G_t\|_{\mathrm{F}}$ 衡量跟踪误差。本文全梯度矩阵实验没有抽样噪声，不能把所有改善都归因于“降噪”。$\beta = 0$ 时 $M_t = H_t = G_t$，历史影响消失。

零初始化导致 $M_0 = (1-\beta)G_0$，这里不进行 Adam 式偏差修正。Nesterov 风格混合具体为 $H_t = (1-\beta)G_t + \beta M_t$，依据参考实现，不能由名称推断经典 Nesterov 加速速率。后文证明会显式保留历史滞后与初始化两类代价。

s 控制额外尺度，λ 为解耦权重衰减。真实位移还包含 $-\eta_t\lambda W_t$，理论实验取 $s = 1, \lambda = 0$。更换 s 就改变了有效步长 $\eta_t s$；仅说“学习率相同”还不足以保证更新尺度相同。

设置	尺度 s	本文用途
无形状缩放	1	全部矩阵理论及受控实验
Jordan 约定	$\sqrt{\max(1, m/n)}$	小型网络的隐藏层
Moonlight 约定	$0.2\sqrt{\max(m, n)}$	代码提供接口，本次未使用

表 1: 不同尺度约定需与学习率一起解释，不共用同一套理论常数。

2.6 Newton–Schulz：把谱变换变成矩阵乘法

SVD 适合精确解释和小规模核查。NS 的目的，是用矩阵乘法近似重塑奇异值，便于实际硬件实现；本项目只验证 CPU/float64 行为，没有测速或证明 GPU 加速比。先取

$$X_0 = H/(\|H\|_{\mathrm{F}} + 10^{-7}), \qquad \|X_0\|_{\mathrm{op}} \le 1,$$

再迭代

$$A_j = X_j X_j^{\top}, \quad X_{j+1} = aX_j + (bA_j + cA_j^2)X_j, \quad (a, b, c) = (3.4445, -4.7750, 2.0315). \tag{13}$$

默认 $K = 5$。当行数大于列数时先转置，令 Gram 矩阵在较小维度计算，最后转回。

若 $X_j = U\,\mathrm{diag}(x_{i,j})V^{\top}$，代入式(13)得到

$$X_{j+1} = U\,\mathrm{diag}\big(p(x_{i,j})\big)V^{\top}, \quad p(x) = ax + bx^3 + cx^5.$$

所以这个矩阵迭代等价于在固定成对方向上逐个应用标量多项式；若系数为负，其绝对值才是奇异值。零系数仍为零，较小正系数在近零区间约被放大 a 倍。理想极分解希望把全部非零系数变为 1，有限步 NS 只能近似完成这一目标。

必须区分 Muon 使用的五阶系数与经典求精确极分解的 NS 迭代。这组系数满足 $p(1) = 0.701 \neq 1$，因此 1 不是固定点，反复应用不能由通常的固定点收敛论证推出精确极分解。精确极分解的尺度不变性也会被分母中的 10^{-7} 轻微破坏，尤其输入很小时。后文使用实际测得的近似误差，而不预设它为零。

3 收敛性结果与证明

3.1 假设及基础不等式

本节仅研究确定性的全梯度更新。假设 f 可微且有下界 f_{low}，取 $L > 0$，并满足

$$\|\nabla f(X) - \nabla f(Y)\|_{\mathrm{F}} \le L\|X - Y\|_{\mathrm{F}}. \tag{14}$$

记 $\Delta = f(W_0) - f_{\mathrm{low}} \geq 0$，$T$ 为正整数。光滑性限制梯度在参数移动后改变得多快；f 可以非凸。由线段积分可得下降引理

$$f(W - \eta D) \leq f(W) - \eta \langle \nabla f(W), D \rangle + \frac{L\eta^2}{2} \|D\|_{\mathrm{F}}^2. \tag{15}$$

其完整推导为

$$\begin{aligned} f(W - \eta D) - f(W) &= -\eta \int_0^1 \langle \nabla f(W - u\eta D), D \rangle \, du \\ &= -\eta \langle \nabla f(W), D \rangle - \eta \int_0^1 \langle \nabla f(W - u\eta D) - \nabla f(W), D \rangle \, du \\ &\leq -\eta \langle \nabla f(W), D \rangle + \eta \int_0^1 Lu\eta \|D\|_{\mathrm{F}}^2 \, du. \end{aligned}$$

积分 $\int_0^1 u \, du = 1/2$ 得到结论。式(15)同时出现了内积与范数：前者是下降收益，后者是曲率误差成本；两者竞争决定有限步长是否下降。

引理 2. 任意 $G, H \in \mathbb{R}^{m \times n}$ 满足

$$\langle G, \mathcal{P}(H) \rangle \geq \|G\|_* - 2\sqrt{r} \|H - G\|_{\mathrm{F}}. \tag{16}$$

证明. 令 $E = H - G$。由 SVD 的定义及 Cauchy–Schwarz 不等式，

$$\begin{aligned} \langle G, \mathcal{P}(H) \rangle &= \|H\|_* - \langle E, \mathcal{P}(H) \rangle \\ &\geq \|G\|_* - \|E\|_* - \sqrt{r} \|E\|_{\mathrm{F}} \\ &\geq \|G\|_* - 2\sqrt{r} \|E\|_{\mathrm{F}}. \end{aligned}$$

最后一步使用 $\|E\|_* \leq \sqrt{r} \|E\|_{\mathrm{F}}$。证明同时覆盖零矩阵和秩亏矩阵。 □

3.2 无动量精确版本

命题 1. 设 $D_t = \mathcal{P}(G_t)$，$W_{t+1} = W_t - \eta D_t$，其中 $\eta > 0$ 为常数。则

$$\frac{1}{T} \sum_{t=0}^{T-1} \|G_t\|_* \leq \frac{\Delta}{\eta T} + \frac{Lr\eta}{2}. \tag{17}$$

若 $\Delta > 0$ 并取 $\eta = \sqrt{2\Delta/(LrT)}$，则

$$\min_{0 \leq t < T} \|G_t\|_{\mathrm{F}} \leq \frac{1}{T} \sum_{t=0}^{T-1} \|G_t\|_* \leq \sqrt{\frac{2Lr\Delta}{T}}. \tag{18}$$

证明. 将 $\langle G_t, D_t \rangle = \|G_t\|_*$ 和 $\|D_t\|_{\mathrm{F}}^2 \leq r$ 代入下降引理，得

$$\eta \|G_t\|_* \leq f(W_t) - f(W_{t+1}) + Lr\eta^2/2.$$

对 $t = 0, \ldots, T-1$ 求和，函数值项望远镜消去，再利用 $f(W_T) \geq f_{\mathrm{low}}$，即得式(17)。代入给定步长并使用 $\|G\|_{\mathrm{F}} \leq \|G\|_*$ 即得式(18)。 □

式(17)中，$\Delta/(\eta T)$ 是初始目标差摊到每步后的项，$Lr\eta/2$ 是曲率项。预算越长，前一项越小；步长越大，后一项越大。平衡这两项才得到 $\eta(T) \propto T^{-1/2}$。

定义时间平均指标

$$\overline{g}_{*,T} = \frac{1}{T}\sum_{t=0}^{T-1} \|G_t\|_*.$$

这是“先在每一步求梯度核范数，再对时间取平均”，并不是平均梯度的范数 $\|T^{-1}\sum_t G_t\|_*$；后者可因方向抵消而很小。例如 $G_0 = A, G_1 = -A$ 时，后者为零，前者仍为 $\|A\|_*$。图上的种子平均又是另一个层次：先独立计算每个种子的 $\overline{g}_{*,T}$，再画它们的均值与范围。

更严格地说，式(18)给出至少一个已访问点的驻点性保证。若从 $0, \dots, T-1$ 均匀抽取 R，则 $\mathbb{E}\|G_R\|_{\mathrm{F}} \le \overline{g}_{*,T}$；这里的期望来自随机选迭代编号，非随机梯度假设。它不保证最后一步梯度具有同一上界。达到 $\min_t \|G_t\|_{\mathrm{F}} \le \varepsilon$ 的充分预算为 $T \ge 2Lr\Delta/\varepsilon^2$，仍需按预算设置步长。

这是对梯度指标的界，不是对函数值差 $f(W_T) - f_*$ 的界，也没有证明整个参数序列趋于某个点。对固定 η，式(17)留下 $Lr\eta/2$，不能据此宣称梯度最终为零。若 $\Delta = 0$，初值已达到下界，可直接停止。

3.3 带动量的精确版本

命题 2. 设 $0 \le \beta < 1$ 固定，$q \in \{1, \beta\}$，并采用前述动量和精确极分解，$s = 1, \lambda = 0$。令

$$C_\beta = \frac{1}{2} + \frac{2q\beta}{1-\beta}.$$

则常步长运行 T 步满足

$$\frac{1}{T}\sum_{t=0}^{T-1} \|G_t\|_* \le \frac{\Delta}{\eta T} + LrC_\beta\eta + \frac{2\sqrt{r}\, q\beta\|G_0\|_{\mathrm{F}}}{T(1-\beta)}. \tag{19}$$

若 $\Delta > 0$，取 $\eta = \sqrt{\Delta/(LrC_\beta T)}$ 后，右端为 $2\sqrt{\Delta LrC_\beta/T} + O(T^{-1})$。

证明. 令 $E_t = M_t - G_t$。初始误差为 $E_0 = -\beta G_0$。对 $t \ge 1$，

$$E_t = \beta E_{t-1} + \beta(G_{t-1} - G_t).$$

精确更新的长度不超过 $\eta\sqrt{r}$，故梯度差范数不超过 $L\eta\sqrt{r}$。递推展开得

$$\|E_t\|_{\mathrm{F}} \le \beta^{t+1}\|G_0\|_{\mathrm{F}} + \frac{\beta L\eta\sqrt{r}(1-\beta^t)}{1-\beta}.$$

求平均并用几何级数求和，得到

$$\frac{1}{T}\sum_t \|E_t\|_{\mathrm{F}} \le \frac{\beta\|G_0\|_{\mathrm{F}}}{T(1-\beta)} + \frac{\beta L\eta\sqrt{r}}{1-\beta}. \tag{20}$$

因为 $H_t - G_t = qE_t$，引理给出 $\langle G_t, D_t\rangle \ge \|G_t\|_* - 2q\sqrt{r}\|E_t\|_{\mathrm{F}}$。将其代入下降引理，求和后使用上述平均误差界，整理即得式(19)。 □

式(19)的三项分别是初始目标差、持续的历史滞后代价、零初始化的短暂代价。固定 β 时后者为 $O(T^{-1})$，前两项平衡后为 $O(T^{-1/2})$。$\beta \to 1$ 时常数增大，所以这个上界没有证明动量加速；上界常数变大也不能证明动量实际更差。

在 Nesterov 混合的 $\beta = 0.9$ 下，$q = 0.9$，$C_\beta = 16.7$；无动量时为 0.5。同一目标、种子与预算下，按各自定理选择的步长之比为

$$\frac{\eta_{\beta=0.9}}{\eta_{\beta=0}} = \sqrt{\frac{0.5}{16.7}} \approx 0.1730. \tag{21}$$

因此，原速率图适合分别验证各自的界，不能从橙蓝曲线高低识别动量的单独作用。本版另补同学习率对照。

3.4 有限步近似能验证什么

令实际方向为 D_t，近似误差为 $\delta_t = \|D_t - \mathcal{P}(H_t)\|_{\mathrm{F}}$。由引理和内积不等式，

$$\langle G_t, D_t \rangle \geq \|G_t\|_* - 2\sqrt{r}\|H_t - G_t\|_{\mathrm{F}} - \|G_t\|_{\mathrm{F}}\delta_t. \tag{22}$$

因此，对任意正步长序列，在无衰减、无额外缩放的更新下，

$$\frac{\sum_t \eta_t \|G_t\|_*}{\sum_t \eta_t} \leq \frac{\Delta + \sum_t \eta_t B_t}{\sum_t \eta_t}, \qquad B_t = 2\sqrt{r}\|H_t - G_t\|_{\mathrm{F}} + \|G_t\|_{\mathrm{F}}\delta_t + \frac{L\eta_t}{2}\|D_t\|_{\mathrm{F}}^2. \tag{23}$$

证明. 写 $D_t = \mathcal{P}(H_t) + (D_t - \mathcal{P}(H_t))$。对第二项应用式(5)，对第一项应用式(16)，得到前述内积下界。代入下降引理并移项，

$$\eta_t \|G_t\|_* \leq f(W_t) - f(W_{t+1}) + \eta_t B_t.$$

从 $t = 0$ 到 $T - 1$ 求和，利用 $f(W_T) \geq f_{\mathrm{low}}$，再除以正数 $\sum_t \eta_t$ 即得。 □

B_t 的三项分别对应动量输入偏离当前梯度、NS 偏离精确方向、有限位移的曲率成本。常步长时左边是普通时间平均；变步长时则是学习率加权平均，不能改成同一个无权平均。代码记录并核查这些量，这是包含实测误差的事后界；若缺少误差随预算的先验控制，不能称为五步 Muon 的无条件 $O(T^{-1/2})$ 定理。

例如，在无动量的常步长近似更新中，若额外已知每步 $\delta_t \leq \rho < 1$ 且 $\|D_t\|_{\mathrm{F}} \leq B$，则 $\|G_t\|_{\mathrm{F}} \leq \|G_t\|_*$ 给出

$$(1 - \rho)\frac{1}{T}\sum_t \|G_t\|_* \leq \frac{\Delta}{\eta T} + \frac{L\eta B^2}{2}.$$

这说明获得先验速率需要何种额外控制。谱图中的误差是相对误差，不能直接当作这里要求的绝对 δ_t；本项目未证明 NS5 在所有优化步骤满足这些条件。

4 仿真设计：每个实验回答哪个问题

4.1 目标、精度与统计方式

矩阵实验使用 12×8 参数、float64、种子 $0, \ldots, 4$。每一目标与种子内，所有方法共享初值；种子之间的目标及初值也会改变，所以阴影包含问题实例的差异，不只是优化器随机性。实线为种子算术均值，阴影为最小值到最大值，不是置信区间。矩阵优化器使用全梯度，每个给定实例的更新是确定性的。

二次目标为

$$f(W)=\tfrac{1}{2}\|\operatorname{diag}(\sqrt{h})Q(W-W_\star)\|_{\mathrm{F}}^2,\quad h_i\in[1,30],\quad Q^\top Q=I.$$

h_i 按几何序列取值，故 $L=30$，$f_*=0$ 在 $W_\star$ 达到。W_0 元素独立服从标准正态分布，$W_\star$ 元素为标准正态数除以 $\sqrt{12}$。

非凸目标为

$$f(W)=\tfrac{1}{2}\sum_{ij}h_i(W_{ij}-W_{\star,ij})^2+0.2\sum_{ij}(1-\cos W_{ij}),\quad h_i\in[0.02,1].$$

这里 $Q=I$，h_i 按几何序列取值。Hessian 对角项为 $h_i+0.2\cos W_{ij}$，绝对值不超过 1.2，因此 $L=1.2$。当最小曲率方向的元素为 π 时，对角项为 $-0.18<0$，故确实非凸。两项均非负，$f_{\mathrm{low}}=0$ 有效，但不声称 0 为可达到的最优值；这类图只标目标值，不标最优差。

4.2 独立预算 T 与当前步数 t

独立预算实验取 $T\in\{64,128,256,512,1024,2048,4096\}$。对于同一目标、种子和动量设置，每个 T 从同一个 W_0 重新出发，整次运行使用依赖 T 的常步长。横轴的一个点代表整次运行，纵轴是该次运行的 $\overline{g}_{*,T}$，而不是第 T 步的损失或梯度。$T=64$ 与 $T=128$ 两次运行连第一步的步长都不同，不能视作同一条轨迹的前后两段。

轨迹实验则固定总预算 $T=2048$，在一次运行内记录 W_t。横轴 t 是已完成的更新次数，$t=0$ 表示初值，$t=2048$ 表示 W_T。新版每 8 步记录一次，并显式保存终点。原轨迹文件最后记录的是更新前 W_{2047}；原汇总文件的 `final_value` 才对应 W_{2048}。两种索引不混用。

	独立预算图	单次运行轨迹图
横轴	总预算 T，每点重新运行	当前步数 t，沿同一条轨迹
学习率	每次运行取 $\eta(T)$，运行内固定	固定 η_0 或给定 η_t 日程
纵轴	$T^{-1}\sum_{t<T}\|G_t\|_*$	当前 $f(W_t)$ 或 $\|G_t\|_{\mathrm{F}}$
目的	对照有限预算上界及速率阶	观察瞬时下降、振荡及末期行为

表 2: 两个横轴的符号接近，但统计对象不同。

4.3 受控因子实验：分别改变动量、近似和步长

原轨迹包含 SVD/无动量与 NS5/动量的两类组合，直接相减会同时混入两个因素。本版增加完整的

$$\{\mathrm{SVD},\mathrm{NS5}\}\times\{\beta=0,0.9\}\times\{\text{固定步长},\text{衰减步长}\}$$

对照，在两类目标、五个种子上共运行 $2\times5\times8=80$ 组，每组 2048 步。所有组固定 Nesterov 混合公式、$K=5$、$s=1$、$\lambda=0$；仅按实验设计改变相应因素。对每个问题实例，共享

$$\eta_0=\sqrt{\frac{2\Delta}{Lr\cdot2048}},\qquad \eta_t=\begin{cases}\eta_0, & \text{固定组},\\ \eta_0/(1+t/64)^{0.6}, & \text{衰减组}.\end{cases}\tag{24}$$

不同种子有各自的 Δ，故学习率只在*配对实例*内一致，不宣称全部种子用同一个数。

比较动量时，在同一目标与步长日程内固定 SVD 或 NS5，只比较 $\beta = 0$ 与 0.9。比较近似方法时固定 β，只比较 SVD 与 NS5。比较步长时固定方法和动量，只比较两种日程。共同学习率控制了显式超参数，但 NS 会改变 $\|D_t\|_{\mathrm{F}}$，动量也会改变输入，因此真实位移 $\eta_t D_t$ 不会完全相等；这些变化属于方法本身的作用。这里不额外归一化方向，以免改变被研究的算法。由于不同方法逐步走向不同的 W_t，后续梯度也会不同，这是轨迹比较的自然结果。

所有比较都使用相同更新次数，没有计时，不能推导相同计算成本下的性能；也没有分别寻找最优学习率，结论限于式(24)这一预设方案。共享学习率的动量组不再使用其定理最优步长，但仍可逐步核查含误差的通用不等式。

4.4 小型神经网络及参数组学习率

网络为 $10 \to 24 \to 3$ 的两层 tanh 回归模型，共 339 个参数。每个种子使用教师网络生成 512 个训练样本和 256 个独立测试样本，噪声标准差为 0.03。损失为

$$f_{\text{train}}(W) = \frac{1}{2 \cdot 512 \cdot 3} \sum_{i=1}^{512} \sum_{j=1}^{3} (\widehat{y}_{ij} - y_{ij})^2.$$

反向传播使用相同的平均约定。mini-batch 大小为 64，更新 800 步；每 20 步用*全训练集*和全测试集评估，因此图上的训练损失不是单个 mini-batch 的损失。测试数据不参与梯度或调参。

训练方案	参数组	优化器	学习率
混合方案	隐藏层矩阵 W_1	Muon NS5，$\beta = 0.95$	0.02
混合方案	b_1, W_2, b_2	辅助 AdamW	0.003
全 AdamW	全部参数	AdamW	0.003

表 3: 两个训练方案的隐藏层学习率不同。混合方案启用 Jordan 缩放，W_1 形状为 10×24，本例 $s = 1$。

AdamW 参数为 $(\beta_1, \beta_2, \epsilon) = (0.9, 0.999, 10^{-8})$，全部参数组权重衰减均为 0.01。两方案共享数据、初值和每一步 mini-batch。隐藏层学习率与优化器同时改变，且解耦衰减每步强度也依赖学习率；所以它是两套预设训练方案的对比，不是只改变优化器的消融。此处沿用原实验作为流程示例，不用它识别动量或 NS 的单独贡献。

5 结果与图表解读

5.1 预算图：同时看平均梯度与学习率

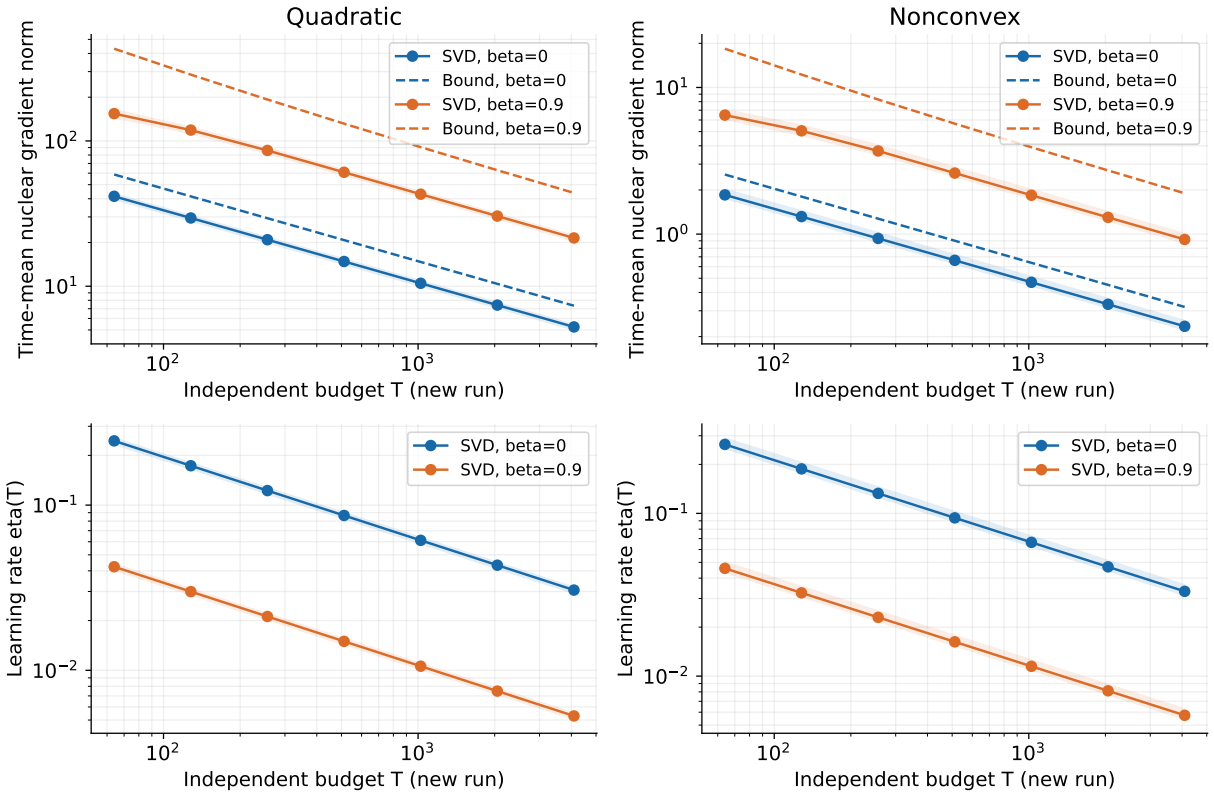


图 1: 重绘原始 `rates.csv`。上排是时间平均梯度核范数及各自的理论界，下排是每次独立运行实际使用的常学习率。每个点都是重新运行后的统计；上下排共用独立预算 T。实线为种子均值，阴影为种子范围。

先读坐标。 上排纵轴不是损失，也不是末步梯度。双对数坐标中，随 T 增大而下降说明更长预算配合更小步长时，时间平均梯度指标变小。虚线是按各自初值计算的理论上界再取种子平均，而不是拟合线。

再读数值。 原有 $2 \times 2 \times 5 \times 7 = 140$ 组运行中，违反上界的次数为 0，最大“实测值/上界”为 0.7400。对种子均值做双对数最小二乘拟合，无动量的二次与非凸斜率分别为 -0.498、-0.496；动量对应 -0.481、-0.478。它们与这些有限预算中的 $T^{-1/2}$ 趋势相容；有限拟合不能证明一般速率或上界最优性。

最后判断可比性。 下排显示动量组学习率更小，比例见式(21)。例如 $T = 2048$ 时，二次问题无动量的种子平均学习率约 0.04327、平均梯度指标约 7.414；动量组对应约 0.007487 和 30.394。后者较高可能包含保守步长造成的早期下降较慢，不能直接说“动量使优化变差”。这张图验证各自的界；下一组图控制学习率后再比较因素。

5.2 原轨迹：能看步长作用，不能拆出动量或近似的贡献

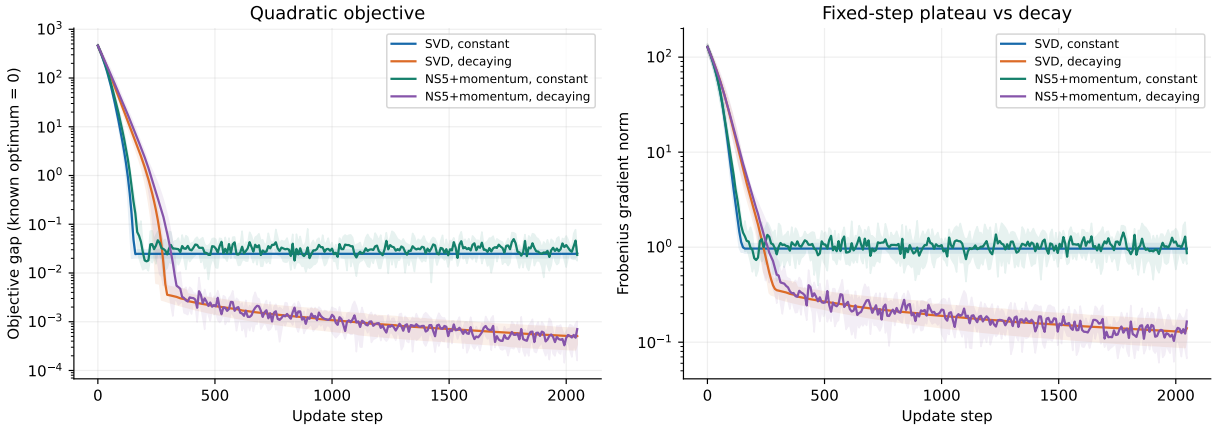


图 2: 保留原轨迹图。横轴是一次运行内的当前步数；左边为二次目标差，右边为当前梯度 Frobenius 范数。SVD 组无动量，NS5 组带 $\beta = 0.9$ 动量；两因素同时改变。

该图适合在*同一种方法内*对比固定与衰减步长，因为初值、算法和初始步长保持相同，只更换日程。固定 SVD 版本的最终目标差均值为 0.024714，衰减后为 0.000500；NS5 加动量对应 0.037491 和 0.000345。这支持“衰减在本例减小末期误差”，不能从 NS5 与 SVD 的交叉比较中区分动量和近似的作用。

右图显示当前梯度的幅度，不是前图的时间平均核范数。固定步长的正交化更新在梯度变小时未必同步缩短，末期可能跨过最优点；衰减日程缩短位移，因而平台下降。对这一个正定二次目标，函数值差和梯度平方存在 Hessian 特征值控制的联系，但它不是一般非凸目标中可无条件使用的等式。

5.3 新增受控轨迹：一次只比较一个因素

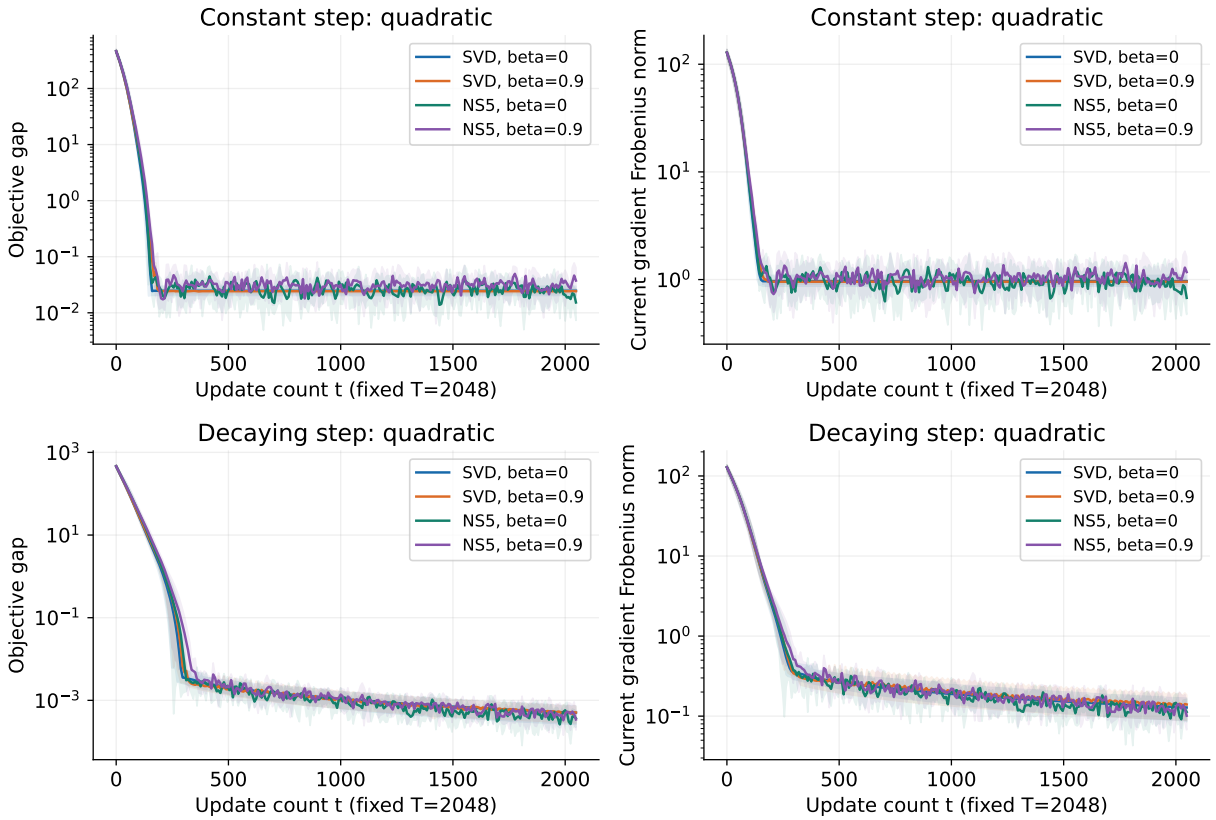


图 3: 二次目标的受控对照。上排固定学习率，下排衰减学习率；左列目标差，右列当前梯度 Frobenius 范数。每个目标实例内四种方法使用相同日程。蓝/橙固定 SVD 比动量，绿/紫固定 NS5 比动量；蓝/绿固定无动量比近似，橙/紫固定动量比近似。

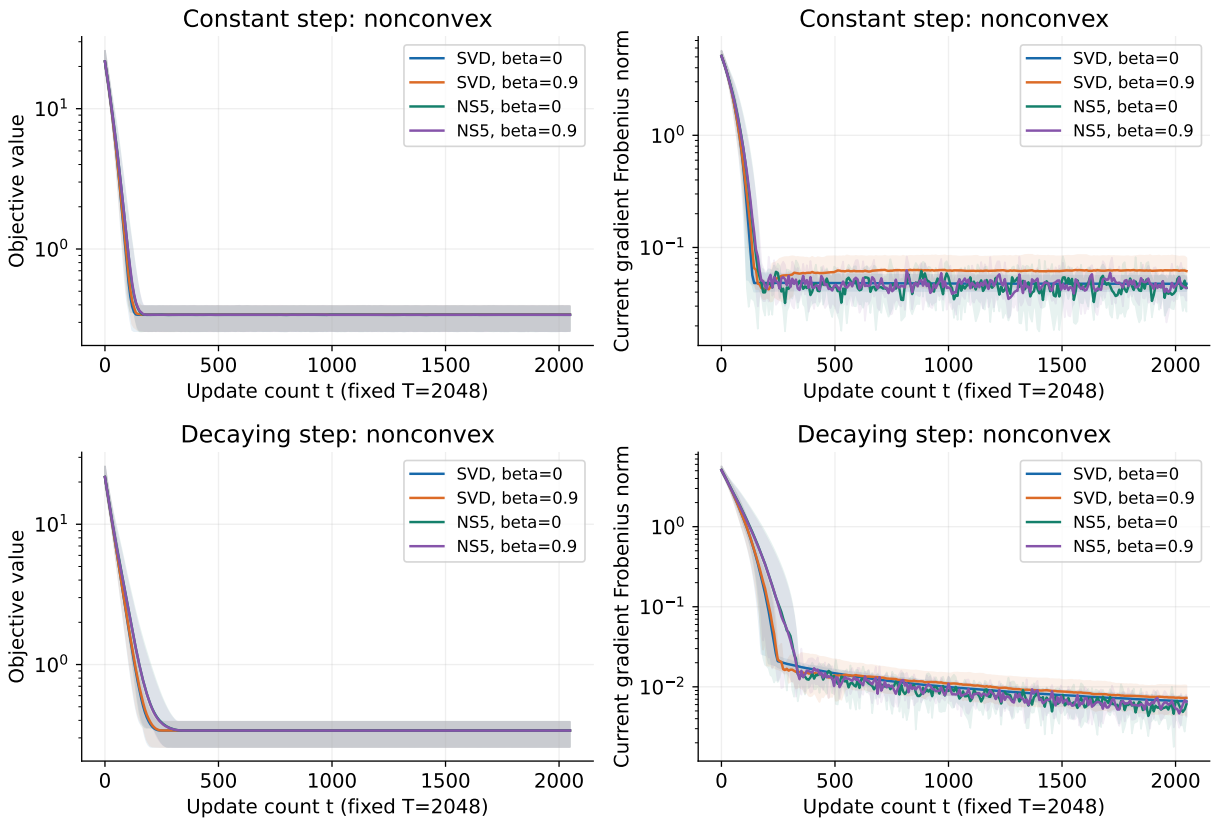


图 4: 非凸目标采用与图3相同的对照结构。左列只表示目标值，因为 0 是已知下界，未证明是最优值。$t = 2048$ 处显式记录全部更新后的参数。

目标	步长	方向与动量	$f(W_T)$	$\|G_T\|_{\mathrm{F}}$
二次	固定	SVD, $\beta = 0$	0.024714	0.966736
二次	固定	SVD, $\beta = 0.9$	0.024270	0.955637
二次	固定	NS5, $\beta = 0$	0.015271	0.675672
二次	固定	NS5, $\beta = 0.9$	0.037491	1.173654
二次	衰减	SVD, $\beta = 0$	0.000500	0.128138
二次	衰减	SVD, $\beta = 0.9$	0.000508	0.139911
二次	衰减	NS5, $\beta = 0$	0.000367	0.112691
二次	衰减	NS5, $\beta = 0.9$	0.000345	0.101095
非凸	固定	SVD, $\beta = 0$	0.339755	0.047462
非凸	固定	SVD, $\beta = 0.9$	0.340747	0.061676
非凸	固定	NS5, $\beta = 0$	0.339609	0.043600
非凸	固定	NS5, $\beta = 0.9$	0.339653	0.043653
非凸	衰减	SVD, $\beta = 0$	0.338247	0.006582
非凸	衰减	SVD, $\beta = 0.9$	0.338254	0.007270
非凸	衰减	NS5, $\beta = 0$	0.338241	0.006072
非凸	衰减	NS5, $\beta = 0.9$	0.338245	0.006480

表 4: 80 组新增运行的末步指标，均为五个种子的算术均值；$T = 2048$。每行同时列出损失和当前梯度，避免用一个指标替代另一个。

表4给出可逐项对照的结果。以二次目标为例，固定 SVD 时加入动量后，固定步长的末步目标差由 0.024714 变为 0.024270，变化较小；衰减步长时则由 0.000500 变为 0.000508，没有一致改善。固定 NS5 时，动量在固定步长下将末步目标差从 0.015271 增至 0.037491，而在衰减步长下从 0.000367 降至 0.000345。因而“动量总会降低末期误差”不符合这组受控结果。

固定无动量时，NS5 在二次目标两种日程下的末步目标差都低于 SVD；但固定 $\beta = 0.9$ 时，固定步长下 NS5 的 0.037491 高于 SVD 的 0.024270，而衰减下次序反转。这表明近似方法的表现与动量、步长有交互，无法仅由“更接近精确极分解”推出末步损失更低。非凸目标在衰减组中的损失均值均约为 0.33824，而梯度范数仍约为 0.0061–0.0073；目标值接近不意味着驻点性指标完全相同。这些数值是有限种子的描述，未进行显著性检验，不按微小均值差给方法做普遍排名。

共同日程下 NS5 仍与 SVD 有差异，这是方向谱及位移长度改变的综合结果。该受控实验比原图更能定位因素，但没有告诉我们每种方法调参后的最优结果，也没有把步数换算成相同计算预算。在非凸图中，损失和梯度曲线可能以不同尺度下降；驻点性、目标值与最优性仍须分别解释。80 组运行均核查式(23)及逐步下降不等式，验证的是实际误差项被正确纳入。

5.4 谱图与一维振荡：解释近似和步长的机制

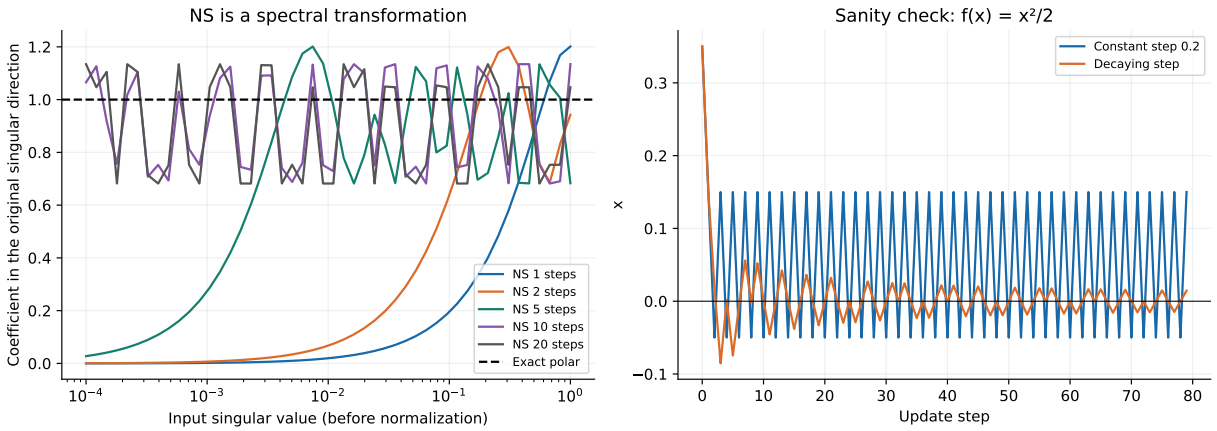


图 5: 左：同一对角输入的谱变换，固定输入、精度、归一化和系数，仅改变 NS 次数。横轴是归一化前的奇异值；虚线 1 是精确极分解的非零系数。右：固定同一目标 $f(x) = x^2/2$ 与初值，只改变符号更新的步长日程。

左图输入为 $\mathrm{diag}(\sigma)$，48 个奇异值按几何序列分布在 $[10^{-4}, 1]$，条件数为 10^4。横轴的值先经整个矩阵的 Frobenius 范数归一化，再参与多项式，不能直接把横轴值当作某次迭代的 $x_{i,j}$。五步对较小奇异方向仍有明显残差；更多步能继续放大这些方向，但已较大的系数也会被多项式改变，故误差不必单调改善。

这里报告的是相对 Frobenius 误差 $\|\mathrm{NS}_K(H) - \mathcal{P}(H)\|_{\mathrm{F}} / \|\mathcal{P}(H)\|_{\mathrm{F}}$。五步为 0.512，10 步约 0.202，20 步约 0.215，故“多迭代一定更精确”被该固定输入的结果否定；它也没有说明五步在全部训练输入上误差都等于这个数。与优化轨迹有关的绝对 δ_t 在控制实验 CSV 中单独记录。

右图在一维取 $x_0 = 0.35$，精确极分解方向就是 $\mathrm{sign}(x_t)$。固定 $\eta = 0.2$ 时，$0.35 \to 0.15 \to -0.05 \to 0.15$，此后形成二周期。目标是强凸的，方向也精确，但固定长度仍会跨过最小点；这说明观察到平台不等于程序出错。衰减日程在本图中减小了振荡幅度，这一例子不是任意非凸序

列收敛的证明。

5.5 神经网络：阅读两套训练方案的损失

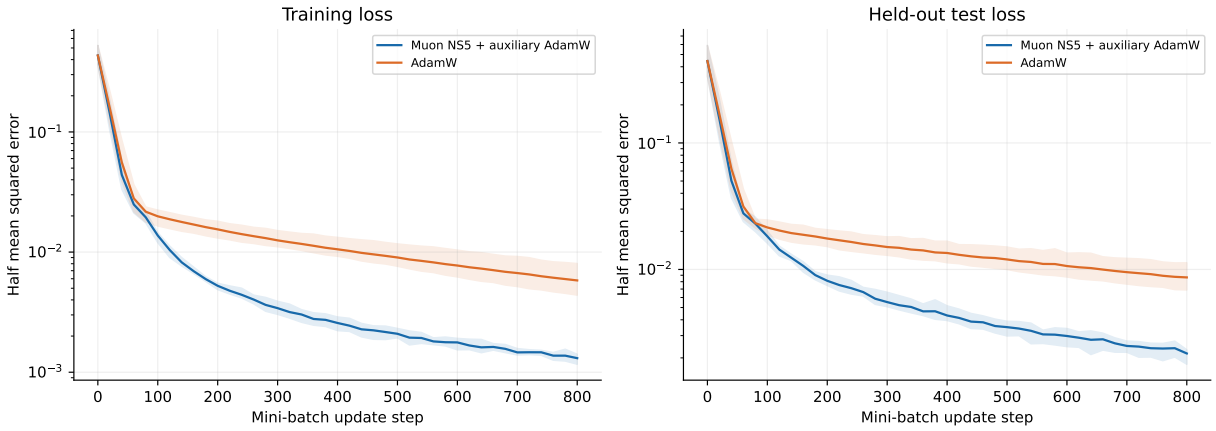


图 6: 原合成回归实验。左为全训练集半均方误差，右为独立测试集半均方误差；横轴是 mini-batch 更新次数，纵轴是损失，未绘制梯度。两方案的隐藏层学习率不同，具体见表3。阴影为五个种子的范围。

第 800 步时，Muon 加辅助 AdamW 的训练/测试损失均值分别为 0.001310/0.002168；全参数 AdamW 对应 0.005808/0.008652。混合方案在这组预设配置中的损失较低。测试损失高于训练损失与存在泛化差距相容；仅凭这两条曲线不能精确分离噪声、样本量与过拟合等因素。

比较时应同时看到：两个方案的隐藏层学习率相差约 6.67 倍、参数组优化器不同，且没有完整超参数搜索。因此这不是在其他条件全部固定时 Muon 对 AdamW 的单因素优势证明，更不能归因为某个动量或 NS 步骤。该网络采用随机 mini-batch、权重衰减及参数分组，不能直接套用前面的全梯度矩阵定理；测试损失下降也没有验证梯度核范数的理论界。

6 复现、编译与检查

原版 `report/muon_report.tex` 与 PDF 保留；新版为同目录下的 `muon_report_v2.tex` 和 PDF。原 `results/` 不覆盖，新增控制实验放入 `results_v2/`。依赖版本见两版汇总 JSON；无需 GPU、PyTorch 或在线数据集。

在仓库根目录运行：

```
python -m pip install -r requirements.txt
OPENBLAS_NUM_THREADS=1 OMP_NUM_THREADS=1 \
  python -m unittest discover -s tests -v
# Reproduce v1 without overwriting the archive
OPENBLAS_NUM_THREADS=1 OMP_NUM_THREADS=1 \
  python -m muon_study.experiments --output /tmp/muon-v1-recheck
# Replot rates.csv and run the 80 controlled experiments
OPENBLAS_NUM_THREADS=1 OMP_NUM_THREADS=1 \
  python -m muon_study.report_v2_experiments --output results_v2
```

随后进入报告目录，编译两遍以解析交叉引用：

```
cd report
xelatex -interaction=nonstopmode -halt-on-error muon_report_v2.tex
xelatex -interaction=nonstopmode -halt-on-error muon_report_v2.tex
```

编译采用 XeLaTeX、Noto Serif/Sans CJK SC 和 DejaVu Sans Mono 字体。原版指标读取 `results/metrics.tex`；新增表格由 `controlled_final.csv` 自动汇总生成，不手抄控制实验数值。自定义种子数或预算后也须同步更新报告中说明的实验配置。

原有 11 项检查覆盖秩亏与零矩阵、极分解恒等式、NS 多项式与转置、动量公式、尺度与衰减、目标有限差分梯度、理论界、全部网络参数组的反向传播以及 AdamW 首步。本次复跑全部通过。原实验在独立目录重跑并与归档数值核对；新增实验对每组同时检查学习率配对、完整终点记录、逐步下降界与加权平均事后界。编译日志、页面与原文件校验结果见 `results_v2/VALIDATION.md`。

文件	用途
`muon_study/optimizers.py`	原优化器实现，本版继续调用
`muon_study/report_v2_experiments.py`	新版预算重绘、受控实验、检查与表格导出
`results/rates.csv`	原始 140 组预算实验及各组学习率
`results_v2/controlled_trajectories.csv`	当前目标、梯度、学习率、方向内积及误差
`results_v2/controlled_final.csv`	每组 W_T 指标与含误差的事后界
`results_v2/summary.json`	新版环境版本及 80 组控制实验汇总

表 5: 新增原始数据与报告的对应关系。

GitHub： `https://github.com/rou521/optimize-and-game`。 新版 TeX、 新版 PDF、 新增实验脚本。 完整工程可用仓库的 `Code` → `Download ZIP`，或 工程 ZIP 链接下载。 `SHA256SUMS.json` 保存文件校验值；GitHub 文件页按 `y` 可获得固定提交链接。

7 结论

损失规定训练的目标，梯度将目标变成局部变化信息，内积衡量给定更新的一阶收益，范数控制幅度与曲率成本。SVD 将矩阵方向和强度分开，精确 Muon 将正奇异值重置为 1，因而同时获得核范数收益与有界位移。动量引入历史信息及跟踪误差，有限步 NS 用矩阵乘法完成近似谱变换并留下近似误差。沿这条链条，精确版本的有限预算证明与实际算法的差别都可以逐项定位。

在明示的全梯度条件下，精确版本及固定动量版本有时间平均梯度的 $O(T^{-1/2})$ 上界。独立预算图用于核查这一命题；同学习率的控制轨迹用于区分因素；谱图解释近似残差；小型网络展示两套完整训练方案的损失表现。四类证据各有用途，均不能单独扩展为随机大模型训练的普遍收敛或优越性结论。

参考文献

[1] Keller Jordan, Yuchen Jin, Vlado Boza, You Jiacheng, Franz Cesista, Laker Newhouse, Jeremy Bernstein. *Muon: An optimizer for hidden layers in neural networks*. 2024. https://github.com/KellerJordan/Muon. 算法简介与引用信息依据作者仓库 README。

[2] Jingyuan Liu, Jianlin Su, Xingcheng Yao, et al. *Muon is Scalable for LLM Training*. 2025. arXiv:2502.16982. https://arxiv.org/abs/2502.16982. 本文阅读的原文来自 MoonshotAI/Moonlight 作者仓库的论文 PDF（固定版本）。

[3] Keller Jordan et al. *Muon reference implementation: muon.py*. 固定提交：`f98f1cacc0263b04290753e32be8d498c1efc806`。 GitHub：Muon 固定版本源码。