Muon 优化器的原理与收敛性分析

矩阵更新、误差界与受控数值实验

算法与数值实验报告

摘要

Muon 通过重塑动量矩阵的奇异值构造更新方向。本文基于损失的一阶展开和矩阵范数对偶性，阐述该方向的几何意义，并推导精确极分解、动量及有限步 Newton–Schulz（NS）近似的收敛界。在确定性全梯度、光滑、有下界且无权重衰减与形状缩放的条件下，精确版本的时间平均梯度核范数具有 $O(T^{-1/2})$ 上界。140 组独立预算实验均满足理论界；80 组受控实验进一步考察动量、近似方法与步长日程的影响。结果表明，动量与近似方法的数值表现存在交互，有限步 NS 的结论须显式保留近似误差。

1 引言

Muon 利用矩阵梯度的奇异结构构造更新，以谱范数约束下的线性化最优方向解释其下降性质。Jordan 等人的实现[1, 3]结合动量与五阶 NS 迭代，主要用于隐藏层矩阵；Liu 等人[2]进一步研究了尺度设置、权重衰减及其在 Moonlight 训练中的应用。本文针对简化的确定性设定，依次分析更新方向、收敛条件及数值证据，并以受控实验区分动量与近似计算的作用。

2 算法原理与实现

2.1 损失、梯度与更新方向

设矩阵参数 $W \in \mathbb{R}^{m\times n}$，监督学习目标可表示为

$$f(W) = \frac{1}{N}\sum_{i=1}^{N} \ell(h_W(x_i), y_i),$$

其中 h_W 为预测模型，ℓ 为单样本损失。训练损失衡量样本拟合程度，独立测试损失用于评估泛化表现。矩阵梯度 $G = \nabla f(W)$ 则表征目标的局部变化：

$$f(W+Z) = f(W) + \langle G, Z\rangle + o(\|Z\|_{\mathrm{F}}). \tag{1}$$

对于更新 $W_{t+1} = W_t - \eta_t D_t$（$\eta_t > 0$），一阶变化为 $-\eta_t\langle G_t, D_t\rangle$。因此，$\langle G_t, D_t\rangle > 0$ 时，$-D_t$ 为下降方向，但有限步长下仍需控制高阶余项。普通梯度下降取 $D_t = G_t$；Muon 则将动量矩阵变换为 D_t，以调整不同奇异方向的相对更新幅度。

损失值与梯度范数分别反映目标水平和驻点性，二者不可等同。在非凸问题中，零梯度亦可能对应局部极大点；例如 $f(x) = 1 + \cos x$ 在 $x = 0$ 处满足 $f'(0) = 0$。

2.2 矩阵内积与范数

记 $r = \min(m, n)$。矩阵内积及三类范数定义为

$$\langle A, B\rangle = \mathrm{tr}(A^\top B) = \sum_{ij} A_{ij} B_{ij}, \tag{2}$$

$$\|A\|_{\mathrm{F}} = \sqrt{\sum_{ij} A_{ij}^2} = \sqrt{\sum_i \sigma_i^2}, \tag{3}$$

$$\|A\|_{\mathrm{op}} = \max_i \sigma_i = \max_{\|v\|_2=1} \|Av\|_2, \qquad \|A\|_* = \sum_i \sigma_i, \tag{4}$$

其中 σ_i 为奇异值。内积衡量一阶下降量，Frobenius 范数量化参数位移及光滑余项，谱范数约束矩阵的最大线性作用，核范数则对应谱范数约束下的最优一阶下降量。由 Cauchy–Schwarz 不等式，

$$|\langle A, B\rangle| \le \|A\|_{\mathrm{F}} \|B\|_{\mathrm{F}}, \qquad \|A\|_{\mathrm{F}} \le \|A\|_* \le \sqrt{r}\|A\|_{\mathrm{F}}. \tag{5}$$

非零梯度的最速下降方向依赖所选约束：Frobenius 单位球对应 $G/\|G\|_{\mathrm{F}}$，谱范数单位球则对应下述极分解方向。

2.3 奇异值分解与极分解

设 $k = \mathrm{rank}(G)$，紧致奇异值分解为

$$G = U_k \Sigma_k V_k^\top = \sum_{i=1}^{k} \sigma_i u_i v_i^\top.$$

左右奇异向量确定成对作用方向，奇异值表征相应强度。定义

$$\mathcal{P}(G) = U_k V_k^\top = \sum_{i=1}^{k} u_i v_i^\top, \qquad \mathcal{P}(0) = 0. \tag{6}$$

该变换保留非零奇异方向，并将对应奇异值统一为 1。例如，$\mathrm{diag}(10, 1)$ 被映射为 I_2，因而不同于对整个梯度作标量归一化。

引理 1. 任意 G 的精确方向满足

$$\langle G, \mathcal{P}(G)\rangle = \|G\|_*, \qquad \|\mathcal{P}(G)\|_{\mathrm{op}} \le 1, \qquad \|\mathcal{P}(G)\|_{\mathrm{F}}^2 = k \le r. \tag{7}$$

并且

$$\max_{\|D\|_{\mathrm{op}} \le 1} \langle G, D\rangle = \|G\|_*. \tag{8}$$

证明. $u_i v_i^\top$ 在 Frobenius 内积下两两正交且范数为 1，故第一式为 $\sum_i \sigma_i$，方向的非零奇异值均为 1，得到另外两式。对任意可行 D，

$$\langle G, D\rangle = \sum_i \sigma_i u_i^\top D v_i \le \sum_i \sigma_i |u_i^\top D v_i| \le \sum_i \sigma_i \|D\|_{\mathrm{op}} \le \sum_i \sigma_i.$$

取 $D = \mathcal{P}(G)$ 达到等号。零矩阵时最优值与选定方向均为零。 □

核范数与秩界分别控制一阶下降量和二阶余项，是后续收敛证明的基础。对于秩亏矩阵，$\mathcal{P}(G)$ 为部分等距映射，不在零奇异值方向补充更新。实现采用 float64 数值秩阈值；理论定义保留全部正奇异值。由于 $\mathcal{P}(cG) = \mathcal{P}(G)$（$c > 0$），精确方向的幅度不随梯度整体缩小而同比下降。

2.4 动量与尺度设置

令 $G_t = \nabla f(W_t)$、$M_{-1} = 0$，更新为

$$M_t = \beta M_{t-1} + (1-\beta) G_t, \qquad 0 \le \beta < 1, \tag{9}$$

$$H_t = G_t + q(M_t - G_t), \qquad q = \begin{cases} 1, & \text{普通动量}, \\ \beta, & \text{Nesterov 型混合}, \end{cases} \tag{10}$$

$$D_t = \mathcal{P}(H_t) \quad \text{或} \quad \mathrm{NS}_K(H_t), \tag{11}$$

$$W_{t+1} = (1 - \eta_t \lambda) W_t - \eta_t s D_t. \tag{12}$$

动量 $M_t = (1-\beta)\sum_{j=0}^{t} \beta^{t-j} G_j$ 对历史梯度作指数加权，可平滑方向波动，同时引入跟踪误差 $\|H_t - G_t\|_{\mathrm{F}}$。零初始化给出 $M_0 = (1-\beta)G_0$，本文不作偏差修正。Nesterov 型混合遵循参考实现，不附带经典加速法的速率保证。$\beta = 0$ 时退化为无动量更新。

s 为形状尺度，λ 为解耦权重衰减系数。矩阵理论与受控实验均取 $s = 1, \lambda = 0$；网络实验采用 Jordan 尺度 $s = \sqrt{\max(1, m/n)}$。由于有效步长为 $\eta_t s$，尺度变化须与学习率共同解释。

2.5 Newton–Schulz 近似

NS 采用矩阵乘法近似实现谱变换。令

$$X_0 = H / (\|H\|_{\mathrm{F}} + 10^{-7}), \qquad \|X_0\|_{\mathrm{op}} \le 1,$$

并迭代

$$A_j = X_j X_j^{\top}, \quad X_{j+1} = a X_j + (b A_j + c A_j^2) X_j, \quad (a, b, c) = (3.4445, -4.7750, 2.0315). \tag{13}$$

默认迭代次数为 $K = 5$。对行数大于列数的矩阵先转置，以减小 Gram 矩阵维度，结束后再转回。若 $X_j = U \,\mathrm{diag}(x_{i,j}) V^{\top}$，则

$$X_{j+1} = U \,\mathrm{diag}(p(x_{i,j})) V^{\top}, \qquad p(x) = ax + bx^3 + cx^5.$$

因此，NS 在固定成对方向上逐个变换系数，其绝对值为输出奇异值。近零正系数约放大 a 倍，但由于 $p(1) = 0.701 \neq 1$，该组系数并非以 1 为固定点的精确极分解迭代，增加次数不保证误差单调下降。归一化中的 10^{-7} 亦使尺度不变性仅近似成立。本文以实测近似误差分析 NS5 的行为，不涉及 GPU 性能评估。

3 收敛性分析

3.1 假设及基础不等式

本节考虑 $s = 1, \lambda = 0$ 的确定性全梯度更新。假设 f 可微且有下界 f_{low}，取 $L > 0$，并满足

$$\|\nabla f(X) - \nabla f(Y)\|_{\mathrm{F}} \le L \|X - Y\|_{\mathrm{F}}. \tag{14}$$

记 $\Delta = f(W_0) - f_{\mathrm{low}} \ge 0$，$T$ 为正整数。不要求 f 为凸函数。由线段积分可得下降引理

$$f(W - \eta D) \le f(W) - \eta \langle \nabla f(W), D \rangle + \frac{L\eta^2}{2} \|D\|_{\mathrm{F}}^2. \tag{15}$$

由微积分基本定理及光滑性，

$$\begin{aligned} f(W-\eta D)-f(W) &= -\eta\int_0^1 \langle \nabla f(W-u\eta D), D\rangle\, du \\ &= -\eta\langle \nabla f(W), D\rangle - \eta\int_0^1 \langle \nabla f(W-u\eta D)-\nabla f(W), D\rangle\, du \\ &\le -\eta\langle \nabla f(W), D\rangle + \eta\int_0^1 Lu\eta\|D\|_{\mathrm{F}}^2\, du. \end{aligned}$$

积分 $\int_0^1 u\,du = 1/2$ 即得式(15)。其中，内积项对应一阶下降量，范数项控制光滑余项。

引理 2. 任意 $G, H \in \mathbb{R}^{m\times n}$ 满足

$$\langle G, \mathcal{P}(H)\rangle \ge \|G\|_* - 2\sqrt{r}\|H-G\|_{\mathrm{F}}. \tag{16}$$

证明. 令 $E = H - G$。由 SVD 的定义及 Cauchy–Schwarz 不等式，

$$\begin{aligned} \langle G, \mathcal{P}(H)\rangle &= \|H\|_* - \langle E, \mathcal{P}(H)\rangle \\ &\ge \|G\|_* - \|E\|_* - \sqrt{r}\|E\|_{\mathrm{F}} \\ &\ge \|G\|_* - 2\sqrt{r}\|E\|_{\mathrm{F}}. \end{aligned}$$

最后一步使用 $\|E\|_* \le \sqrt{r}\|E\|_{\mathrm{F}}$。证明同时覆盖零矩阵和秩亏矩阵。 □

3.2 无动量精确版本

命题 1. 设 $D_t = \mathcal{P}(G_t)$，$W_{t+1} = W_t - \eta D_t$，其中 $\eta > 0$ 为常数。则

$$\frac{1}{T}\sum_{t=0}^{T-1}\|G_t\|_* \le \frac{\Delta}{\eta T} + \frac{Lr\eta}{2}. \tag{17}$$

若 $\Delta > 0$ 并取 $\eta = \sqrt{2\Delta/(LrT)}$，则

$$\min_{0\le t<T}\|G_t\|_{\mathrm{F}} \le \frac{1}{T}\sum_{t=0}^{T-1}\|G_t\|_* \le \sqrt{\frac{2Lr\Delta}{T}}. \tag{18}$$

证明. 将 $\langle G_t, D_t\rangle = \|G_t\|_*$ 和 $\|D_t\|_{\mathrm{F}}^2 \le r$ 代入下降引理，得

$$\eta\|G_t\|_* \le f(W_t) - f(W_{t+1}) + Lr\eta^2/2.$$

对 $t = 0, \dots, T-1$ 求和，函数值项望远镜消去，再利用 $f(W_T) \ge f_{\mathrm{low}}$，即得式(17)。代入给定步长并使用 $\|G\|_{\mathrm{F}} \le \|G\|_*$ 即得式(18)。 □

式(17)中的初始误差项 $\Delta/(\eta T)$ 与光滑项 $Lr\eta/2$ 经平衡后给出 $\eta(T) \propto T^{-1/2}$。其控制的指标为

$$\overline{g}_{*,T} = \frac{1}{T}\sum_{t=0}^{T-1}\|G_t\|_*,$$

即梯度核范数的时间平均，区别于可能因方向抵消而减小的平均梯度范数 $\|T^{-1}\sum_t G_t\|_*$。图中的种子均值是在各次运行的 $\overline{g}_{*,T}$ 上另行计算。

式(18)给出至少一个已访问点的驻点性保证，未给出末步梯度、函数值差或参数序列收敛的保证。对于均匀选取的迭代编号 R，有 $\mathbb{E}\|G_R\|_{\mathrm{F}} \le \overline{g}_{*,T}$；达到 $\min_t \|G_t\|_{\mathrm{F}} \le \varepsilon$ 的充分预算为 $T \ge 2Lr\Delta/\varepsilon^2$。固定步长下仍保留 $Lr\eta/2$ 残差项；若 $\Delta = 0$，初值已达到下界，可直接停止。

3.3 带动量的精确版本

命题 2. 设 $0 \le \beta < 1$ 固定，$q \in \{1, \beta\}$，并采用前述动量和精确极分解，$s = 1, \lambda = 0$。令

$$C_\beta = \frac{1}{2} + \frac{2q\beta}{1-\beta}.$$

则常步长运行 T 步满足

$$\frac{1}{T}\sum_{t=0}^{T-1} \|G_t\|_* \le \frac{\Delta}{\eta T} + LrC_\beta \eta + \frac{2\sqrt{r}\, q\beta \|G_0\|_{\mathrm{F}}}{T(1-\beta)}. \tag{19}$$

若 $\Delta > 0$，取 $\eta = \sqrt{\Delta/(LrC_\beta T)}$ 后，右端为 $2\sqrt{\Delta LrC_\beta/T} + O(T^{-1})$。

证明. 令 $E_t = M_t - G_t$。初始误差为 $E_0 = -\beta G_0$。对 $t \ge 1$，

$$E_t = \beta E_{t-1} + \beta(G_{t-1} - G_t).$$

精确更新的长度不超过 $\eta\sqrt{r}$，故梯度差范数不超过 $L\eta\sqrt{r}$。递推展开得

$$\|E_t\|_{\mathrm{F}} \le \beta^{t+1}\|G_0\|_{\mathrm{F}} + \frac{\beta L\eta\sqrt{r}(1-\beta^t)}{1-\beta}.$$

求平均并用几何级数求和，得到

$$\frac{1}{T}\sum_{t} \|E_t\|_{\mathrm{F}} \le \frac{\beta\|G_0\|_{\mathrm{F}}}{T(1-\beta)} + \frac{\beta L\eta\sqrt{r}}{1-\beta}. \tag{20}$$

因为 $H_t - G_t = qE_t$，引理给出 $\langle G_t, D_t\rangle \ge \|G_t\|_* - 2q\sqrt{r}\|E_t\|_{\mathrm{F}}$。将其代入下降引理，求和后使用上述平均误差界，整理即得式(19)。 □

式(19)分别计入初始目标差、动量跟踪误差与零初始化误差。固定 β 时，初始化项为 $O(T^{-1})$，平衡前两项可保留 $O(T^{-1/2})$ 的速率阶，但该结果不构成动量加速的证明。对于 Nesterov 型混合，$\beta = 0.9$ 时 $C_\beta = 16.7$，无动量时为 0.5，故按各自上界选取的步长满足

$$\frac{\eta_{\beta=0.9}}{\eta_{\beta=0}} = \sqrt{\frac{0.5}{16.7}} \approx 0.1730. \tag{21}$$

该差异须与动量效应区分，相关比较采用同学习率对照。

3.4 有限步近似的误差界

令实际方向为 D_t，近似误差为 $\delta_t = \|D_t - \mathcal{P}(H_t)\|_{\mathrm{F}}$。由引理和内积不等式，

$$\langle G_t, D_t\rangle \ge \|G_t\|_* - 2\sqrt{r}\|H_t - G_t\|_{\mathrm{F}} - \|G_t\|_{\mathrm{F}}\delta_t. \tag{22}$$

因此，对任意正步长序列，在无衰减、无额外缩放的更新下，

$$\frac{\sum_t \eta_t \|G_t\|_*}{\sum_t \eta_t} \le \frac{\Delta + \sum_t \eta_t B_t}{\sum_t \eta_t}, \qquad B_t = 2\sqrt{r}\|H_t - G_t\|_{\mathrm{F}} + \|G_t\|_{\mathrm{F}}\delta_t + \frac{L\eta_t}{2}\|D_t\|_{\mathrm{F}}^2. \tag{23}$$

证明. 写 $D_t = \mathcal{P}(H_t) + (D_t - \mathcal{P}(H_t))$。对第二项应用式(5)，对第一项应用式(16)，得到前述内积下界。代入下降引理并移项，

$$\eta_t \|G_t\|_* \le f(W_t) - f(W_{t+1}) + \eta_t B_t.$$

从 $t = 0$ 到 $T - 1$ 求和，利用 $f(W_T) \ge f_{\mathrm{low}}$，再除以正数 $\sum_t \eta_t$ 即得。 □

B_t 分别包含动量跟踪误差、极分解近似误差和光滑余项。变步长时，左端为学习率加权平均。式(23)属于含实测误差的事后界；获得 NS5 的先验速率仍需进一步控制误差项。

在无动量、常步长且逐步满足 $\delta_t \le \rho < 1$、$\|D_t\|_{\mathrm{F}} \le B$ 的附加条件下，由 $\|G_t\|_{\mathrm{F}} \le \|G_t\|_*$ 可得

$$(1-\rho)\frac{1}{T}\sum_t \|G_t\|_* \le \frac{\Delta}{\eta T} + \frac{L\eta B^2}{2}.$$

本文未证明 NS5 一致满足上述绝对误差条件，谱实验中的相对误差亦不能直接替代 δ_t。

4 实验设计

4.1 目标函数与统计设置

矩阵实验使用 12×8 参数、float64 精度和种子 $0, \dots, 4$。同一目标与种子内，各方法共享初值；不同种子对应不同问题实例。曲线为五个种子的算术均值，阴影为最小值至最大值的范围，不表示置信区间。

二次目标为

$$f(W) = \tfrac{1}{2}\|\operatorname{diag}(\sqrt{h})Q(W - W_\star)\|_{\mathrm{F}}^2, \quad h_i \in [1, 30], \quad Q^\top Q = I,$$

其中 h_i 按几何序列分布，$L = 30$，最优值为 0。W_0 元素服从标准正态分布，$W_\star$ 元素服从标准正态分布后除以 $\sqrt{12}$。非凸目标为

$$f(W) = \tfrac{1}{2}\sum_{ij} h_i (W_{ij} - W_{\star,ij})^2 + 0.2 \sum_{ij} (1 - \cos W_{ij}), \quad h_i \in [0.02, 1],$$

其中 h_i 同样按几何序列分布。Hessian 对角项为 $h_i + 0.2\cos W_{ij}$，绝对值不超过 1.2，故可取 $L = 1.2$；最小曲率方向在 $W_{ij} = \pi$ 时二阶导数为 -0.18，因此目标非凸。其已知下界为 0，但未证明该值可达到。

4.2 预算设置与评价指标

独立预算取 $T \in \{64, 128, 256, 512, 1024, 2048, 4096\}$。每个 T 从同一 W_0 重新运行，采用依赖 T 的常步长，并记录 $\bar{g}_{*,T}$。轨迹实验则固定总预算 $T = 2048$，以当前更新次数 t 为横轴，记录 $f(W_t)$ 与 $\|G_t\|_{\mathrm{F}}$。独立预算图中的各点属于不同运行，轨迹图中的各点属于同次运行；二者的横轴及统计量不可混用。

4.3 动量与近似方法的受控对照

采用完整因子组合

$$\{\text{SVD}, \text{NS5}\} \times \{\beta = 0, 0.9\} \times \{\text{固定步长}, \text{衰减步长}\},$$

在两类目标、五个种子上共进行 80 组运行，每组 2048 步。各组固定 Nesterov 型混合、$K = 5$、$s = 1$、$\lambda = 0$；每个配对实例共享初值及下述学习率日程：

$$\eta_0 = \sqrt{\frac{2\Delta}{Lr \cdot 2048}}, \qquad \eta_t = \begin{cases} \eta_0, & \text{固定组}, \\ \eta_0/(1 + t/64)^{0.6}, & \text{衰减组}. \end{cases} \tag{24}$$

不同种子的 Δ 不同，学习率一致性仅针对配对实例。比较动量时固定极分解方法，比较近似方法时固定 β，比较步长时固定方法与动量。各组每 8 步记录一次，并显式保存 W_{2048}。

共同学习率控制显式步长，未对方法内生的方向范数差异作额外归一化。比较采用相同更新次数，未测量等计算成本性能或进行完整超参数搜索。所有运行均检查式(23)及逐步下降不等式。

4.4 合成回归网络

网络为 $10 \to 24 \to 3$ 的两层 tanh 模型，共 339 个参数。教师网络生成 512 个训练样本与 256 个独立测试样本，输出噪声标准差为 0.03。损失为

$$f_{\text{train}}(W) = \frac{1}{2 \cdot 512 \cdot 3} \sum_{i=1}^{512} \sum_{j=1}^{3} (\widehat{y}_{ij} - y_{ij})^2.$$

mini-batch 大小为 64，更新 800 步，每 20 步在完整训练集与测试集上评估。两方案共享数据、初值及每步 mini-batch，测试集不参与训练或调参。

方案	参数组	优化器	学习率
混合方案	隐藏层矩阵 W_1	Muon NS5，$\beta = 0.95$	0.02
混合方案	b_1, W_2, b_2	辅助 AdamW	0.003
全 AdamW	全部参数	AdamW	0.003

表 1: 网络参数组与学习率。混合方案采用 Jordan 缩放；$W_1 \in \mathbb{R}^{10\times 24}$，因此 $s = 1$。

AdamW 参数为 $(\beta_1, \beta_2, \epsilon) = (0.9, 0.999, 10^{-8})$，各参数组的权重衰减均为 0.01。两方案同时改变隐藏层优化器与学习率，因此该实验比较预设训练配置，不用于识别动量或 NS 的独立效应。

5 数值结果

5.1 独立预算下的收敛界

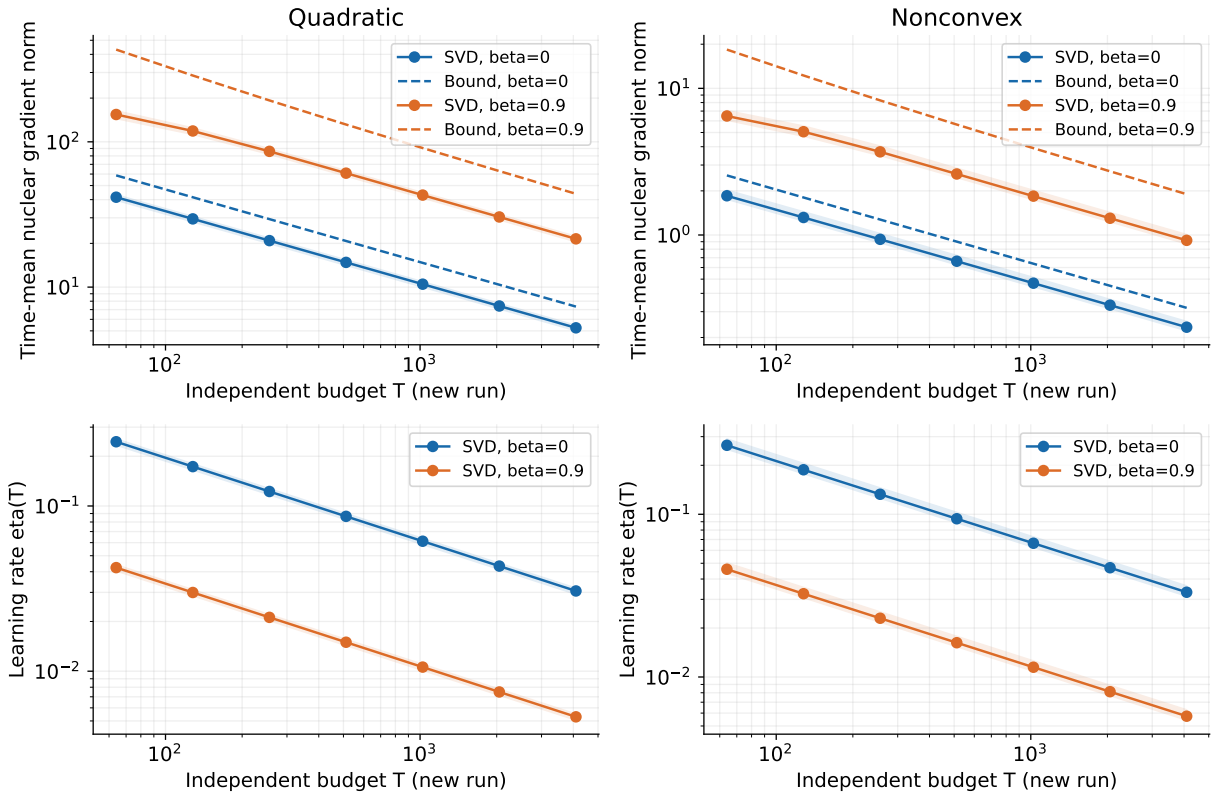


图 1: 独立预算实验。上排为时间平均梯度核范数及对应理论界，下排为各次运行的常学习率；横轴均为预算 T。实线与阴影分别为五种子均值与范围。

140 组运行均满足理论上界，最大实测值与上界之比为 0.7400。无动量版本在二次与非凸目标上的双对数拟合斜率分别为 -0.498、-0.496；动量版本分别为 -0.481、-0.478，与有限预算下的 $T^{-1/2}$ 趋势一致。

图1控制的是梯度核范数的时间平均，而非损失或末步梯度。动量组的理论步长约为无动量组的 17.3%，其曲线差异同时包含学习率影响，不能用于单独评价动量效应。以下采用式(24)统一配对学习率。

5.2 动量、近似方法与步长的交互

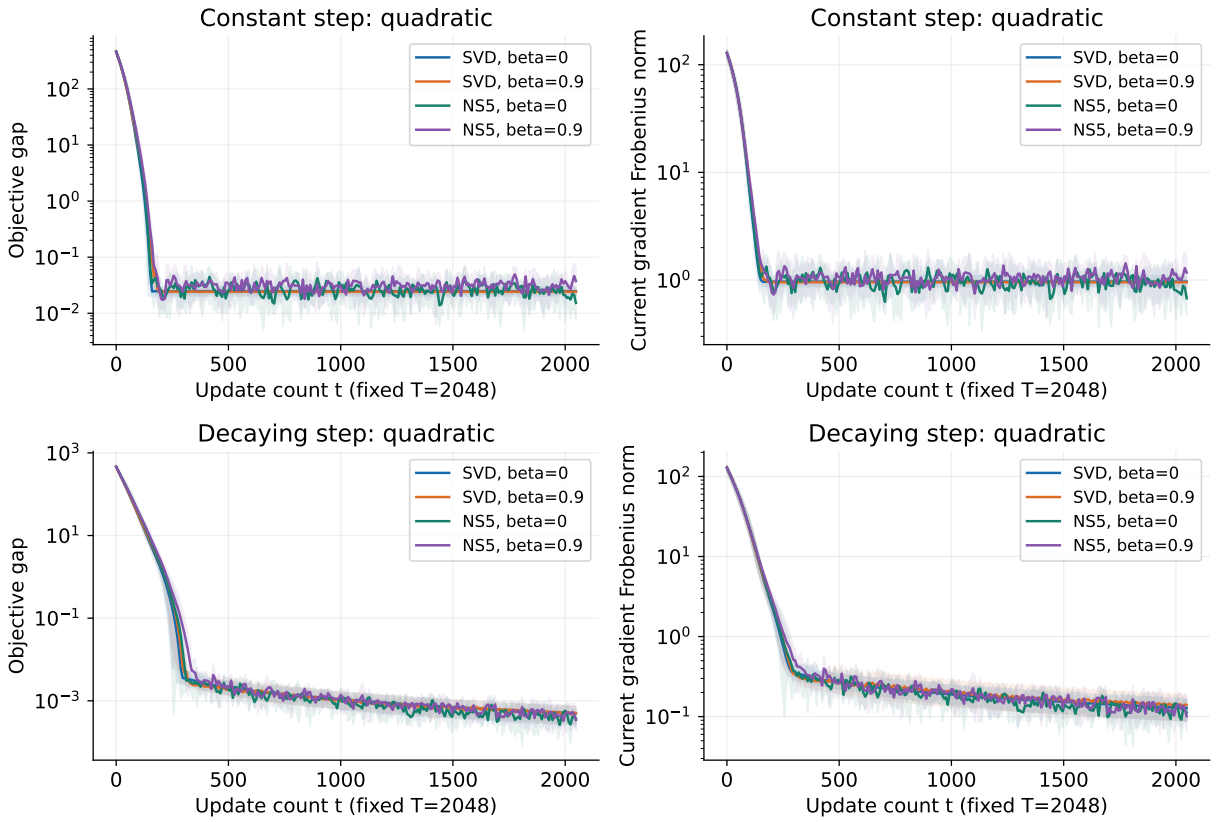


图 2: 二次目标受控轨迹。上、下排分别采用固定与衰减步长；左、右列分别为目标差与当前梯度 Frobenius 范数。每个问题实例内，各方法共享初值与学习率日程。

固定与衰减步长的比较表明，后者减小了本实验的末期误差。以无动量 SVD 的二次目标为例，末步目标差由 0.024714 降至 0.000500。精确方向的幅度不随梯度范数同比缩小，因而固定步长可能导致驻点附近的持续振荡。

动量效果依赖近似方法与步长日程。二次目标中，NS5 在加入动量后，固定步长的末步目标差由 0.015271 增至 0.037491，而衰减步长下由 0.000367 降至 0.000345。SVD 的对应变化较小。固定 $\beta = 0.9$ 时，NS5 与 SVD 的末步误差排序亦随步长日程改变，表明本实验的末步损失未随极分解精度提高而一致降低。

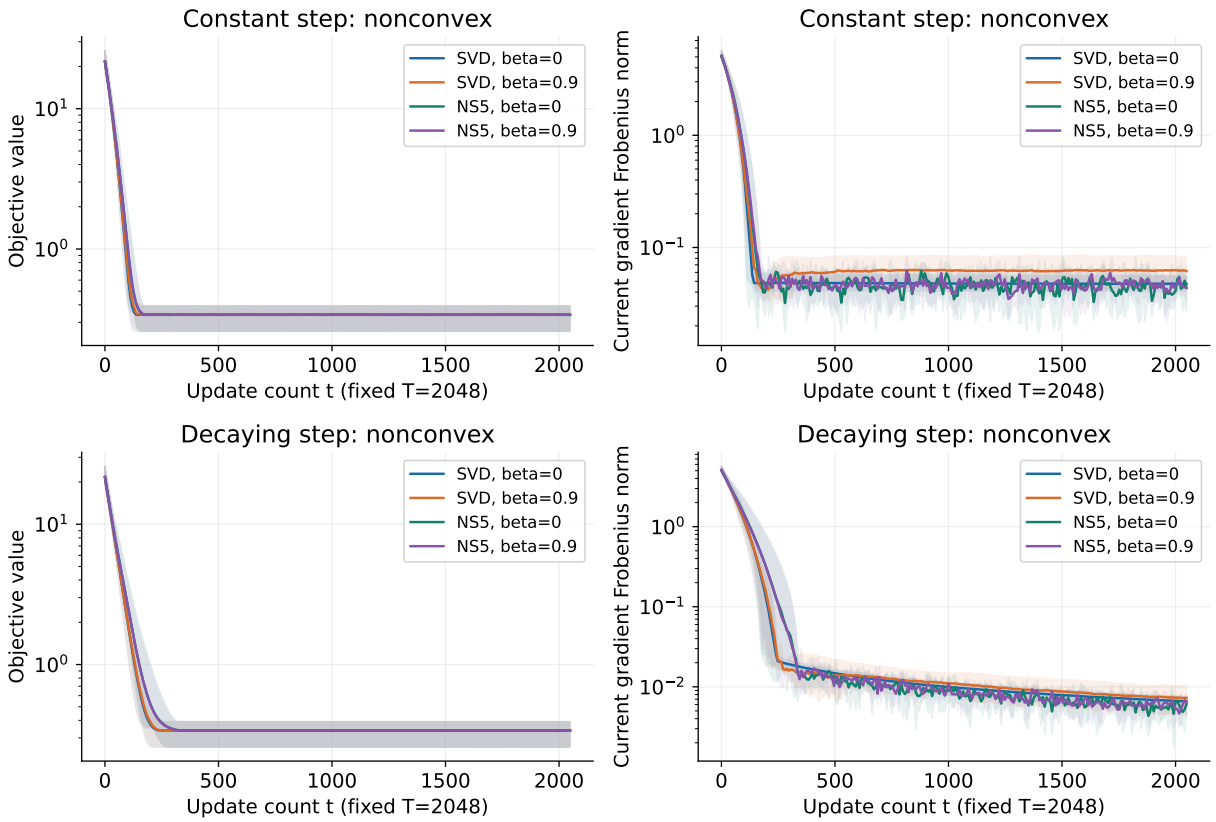


图 3: 非凸目标受控轨迹。配置同图2；左列为目标值，其零下界未被证明为最优值。终点对应全部更新后的 W_{2048}。

非凸目标的衰减组损失均值均约为 0.33824，梯度范数约为 0.0061–0.0073，说明目标值接近时驻点性指标仍可不同。上述结果限于预设学习率与有限问题实例；微小均值差异未经显著性检验。80 组运行均通过含误差下降界检查。

目标	步长	方向与动量	$f(W_T)$	$\|G_T\|_{\mathrm{F}}$
二次	固定	SVD, $\beta = 0$	0.024714	0.966736
二次	固定	SVD, $\beta = 0.9$	0.024270	0.955637
二次	固定	NS5, $\beta = 0$	0.015271	0.675672
二次	固定	NS5, $\beta = 0.9$	0.037491	1.173654
二次	衰减	SVD, $\beta = 0$	0.000500	0.128138
二次	衰减	SVD, $\beta = 0.9$	0.000508	0.139911
二次	衰减	NS5, $\beta = 0$	0.000367	0.112691
二次	衰减	NS5, $\beta = 0.9$	0.000345	0.101095
非凸	固定	SVD, $\beta = 0$	0.339755	0.047462
非凸	固定	SVD, $\beta = 0.9$	0.340747	0.061676
非凸	固定	NS5, $\beta = 0$	0.339609	0.043600
非凸	固定	NS5, $\beta = 0.9$	0.339653	0.043653
非凸	衰减	SVD, $\beta = 0$	0.338247	0.006582
非凸	衰减	SVD, $\beta = 0.9$	0.338254	0.007270
非凸	衰减	NS5, $\beta = 0$	0.338241	0.006072
非凸	衰减	NS5, $\beta = 0.9$	0.338245	0.006480

表 2: 受控实验的末步指标，均为五种子均值，$T = 2048$。

5.3 NS 谱误差与固定步长振荡

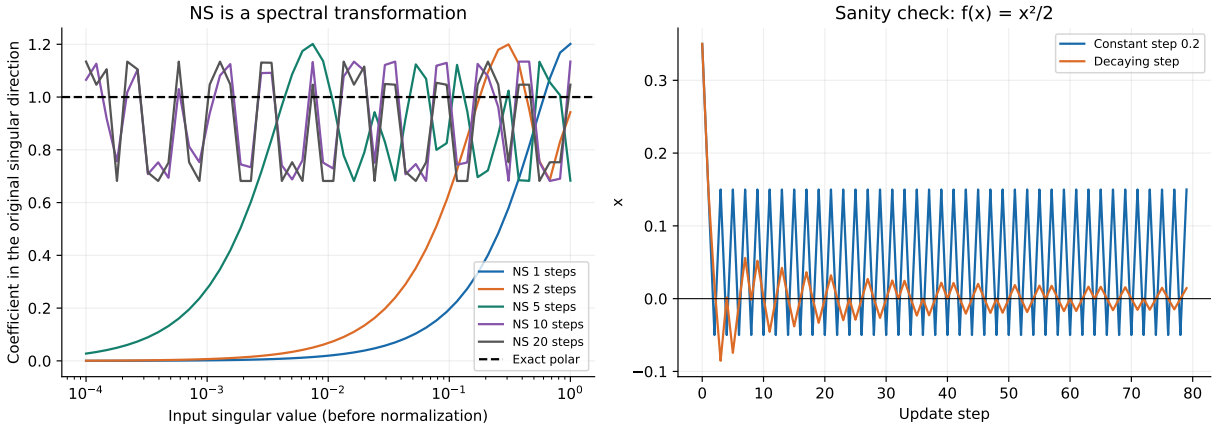


图 4: 左：固定对角输入下的 NS 谱变换，横轴为归一化前奇异值，虚线为精确极分解系数 1。右：$f(x) = x^2/2$ 上固定与衰减步长的符号更新。

谱实验采用 48 个几何分布于 $[10^{-4}, 1]$ 的奇异值，输入先经 Frobenius 范数归一化。相对误差

$$\frac{\|\,\mathrm{NS}_K(H) - \mathcal{P}(H)\|_{\mathrm{F}}}{\|\mathcal{P}(H)\|_{\mathrm{F}}}$$

在 $K = 5, 10, 20$ 时分别为 0.512、0.202、0.215，未随迭代次数单调降低。有限步变换对较弱奇异方向存在残差，同时会继续调整已放大的系数；该现象与 $p(1) \neq 1$ 一致。此处相对误差区别于式(23)中的逐步绝对误差。

一维实验取 $x_0 = 0.35$、$\eta = 0.2$。精确方向为 $\mathrm{sign}(x_t)$，轨迹 $0.35 \to 0.15 \to -0.05 \to 0.15$ 进入二周期，表明即使目标强凸且方向精确，固定步长亦不保证参数收敛。衰减步长在该例中减小了振荡幅度。

5.4 网络训练结果

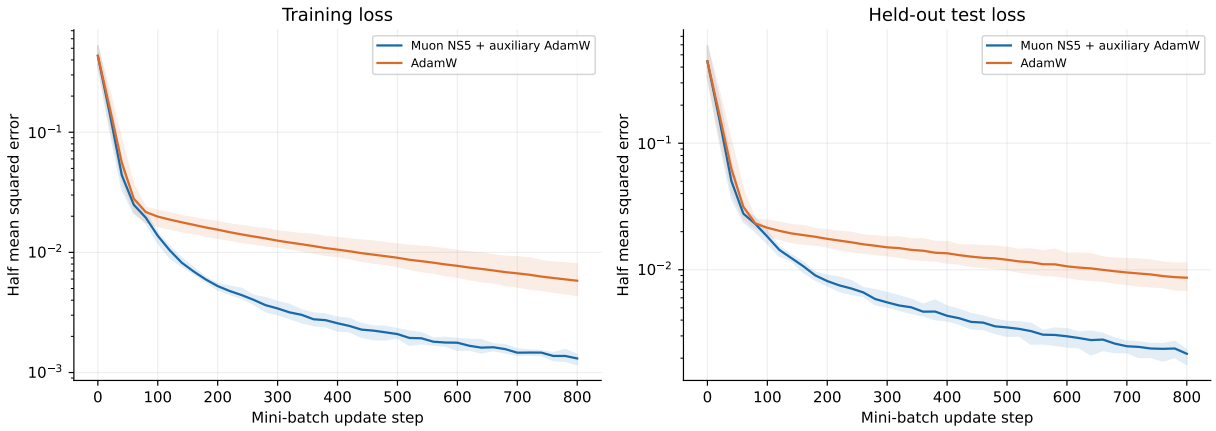


图 5: 合成回归任务的完整训练集损失与独立测试损失。横轴为 mini-batch 更新次数，纵轴为半均方误差；两方案的参数组学习率见表1。

第 800 步时，混合方案的训练/测试损失均值为 0.001310/0.002168，全 AdamW 方案为 0.005808/0.008652。混合方案在该配置下取得较低误差，但其隐藏层学习率约为对照的 6.67 倍，不能据此归结为优化器的单因素优势。该实验包含随机 mini-batch、权重衰减与参数分组，亦不直接适用前述全梯度收敛定理。

6 复现说明

代码、原始 CSV、图表及编译记录均位于 https://github.com/rou521/optimize-and-game。原版报告及 `results/` 保留，受控实验保存于 `results_v2/`。使用 Python、NumPy 与 Matplotlib 在 CPU/float64 下运行；依赖版本见 `requirements.txt`。主要命令为

```
python -m unittest discover -s tests -v
OPENBLAS_NUM_THREADS=1 OMP_NUM_THREADS=1 \
  python -m muon_study.report_v2_experiments --output results_v2
cd report
xelatex -interaction=nonstopmode -halt-on-error muon_report_v2.tex
xelatex -interaction=nonstopmode -halt-on-error muon_report_v2.tex
```

编译需 XeLaTeX、Noto CJK 与 DejaVu 字体。11 项原有数值检查及受控实验的下降界检查均通过，详细记录见 `results_v2/VALIDATION.md`；项目校验值见 `SHA256SUMS.json`。

7 结论

Muon 的精确更新由谱范数约束下的最优一阶方向导出，其核范数下降量与有界 Frobenius 位移共同支持有限预算分析。在所述确定性条件下，精确版本及固定动量版本均具有时间平均梯度核范数的 $O(T^{-1/2})$ 上界；有限步 NS 则需保留近似误差项。受控实验显示，动量、谱近似与步长日程共同影响末期误差，其结论应限定于相应配置与评价指标。

参考文献

[1] Keller Jordan, Yuchen Jin, Vlado Boza, You Jiacheng, Franz Cesista, Laker Newhouse, Jeremy Bernstein. *Muon: An optimizer for hidden layers in neural networks*. 2024. https://github.com/KellerJordan/Muon.

[2] Jingyuan Liu, Jianlin Su, Xingcheng Yao, et al. *Muon is Scalable for LLM Training*. 2025. arXiv:2502.16982. https://arxiv.org/abs/2502.16982. 论文副本： MoonshotAI/Moonlight 作者仓库的论文 PDF（固定版本）。

[3] Keller Jordan et al. *Muon reference implementation: muon.py*. 固定提交：`f98f1cacc0263b04290753e32be8d498c1efc806`。 GitHub：Muon 固定版本源码。